

Отчет по лабораторной работе №1.3

Реализация SOM для визуализации данных

(датасет Wine)

1. Введение

1.1. Цель работы

Изучить архитектуру самоорганизующихся карт Кохонена (SOM) и применить их для визуализации многомерных данных на примере датасета Wine.

1.2. Задачи

1. Реализовать алгоритм обучения SOM с использованием только библиотеки NumPy.
2. Обучить SOM на датасете Wine (13 химических показателей, 3 класса вин).
3. Визуализировать полученную карту признаков с цветовым кодированием кластеров.
4. Интерпретировать результаты: показать, как данные группируются на карте.

2. Теоретическое описание метода

2.1. Самоорганизующаяся карта Кохонена (SOM)

Самоорганизующаяся карта Кохонена (Self-Organizing Map, SOM) — это тип искусственной нейронной сети, использующий обучение без учителя для создания низкоразмерного (обычно двумерного) представления многомерных данных. SOM сохраняет топологические свойства входных данных: близкие точки в исходном пространстве отображаются в соседние нейроны на карте.

Ключевые компоненты алгоритма:

- **Сетка нейронов** размером $m \times n$, каждый нейрон имеет весовой вектор размерности d ;
- **Поиск BMU (Best Matching Unit)** — нейрона, наиболее близкого к входному вектору;
- **Функция соседства** — определяет степень влияния BMU на соседние нейроны (гауссово окно);
- **Обновление весов** — веса BMU и его соседей смещаются в сторону входного вектора;
- **Экспоненциальное затухание** — скорость обучения и радиус соседства уменьшаются с каждой эпохой.

3. Эксперименты

3.1. Датасет Wine

Характеристики:

- **Размерность:** 13 признаков (химические показатели)
- **Количество классов:** 3 (сорта вин)
- **Количество образцов:** 178
- **Источник:** UCI Machine Learning Repository

Признаки:

1. Alcohol (алкоголь)
2. Malic acid (яблочная кислота)
3. Ash (зола)
4. Alcalinity of ash (щелочность золы)
5. Magnesium (магний)
6. Total phenols (общие фенолы)
7. Flavanoids (флавоноиды)
8. Nonflavanoid phenols (нефлавоноидные фенолы)
9. Proanthocyanins (проантоцианины)
10. Color intensity (интенсивность цвета)
11. Hue (тон)
12. OD280/OD315 of diluted wines (оптическая плотность)
13. Proline (пролин)

3.2. Параметры SOM

Параметр	Значение	Примечание
Размер сетки	15 × 15	225 нейронов
Начальная скорость обучения	0.5	Экспоненциальное затухание
Начальный радиус соседства	3.0	Экспоненциальное затухание
Количество эпох	300	Достаточно для сходимости
Метрика расстояния	Евклидова	Стандартная для SOM
Инициализация весов	Случайные выборки из данных	Улучшает сходимость
Разделение данных	80% / 20%	Обучающая / Тестовая

3.3. Предобработка данных

Данные были стандартизированы с использованием `StandardScaler`.

Это необходимо для корректной работы SOM, так как признаки имеют разные масштабы измерений.

4. Результаты экспериментов

4.1. Кривая обучения

Анализ кривой обучения:

Кривая обучения демонстрирует монотонное уменьшение ошибки квантования:

```
Загрузка датасета Wine...
Размерность данных: (178, 13)
Количество классов: 3
Признаки: ['alcohol', 'malic_acid', 'ash', 'alcalinity_of_ash', 'magnesium',
'total_phenols', 'flavanoids', 'nonflavanoid_phenols', 'proanthocyanins',
'color_intensity', 'hue', 'od280/od315_of_diluted_wines', 'proline']
Обучающая выборка: 142 образцов
Тестовая выборка: 36 образцов
```

```
Обучение SOM на датасете Wine...
Эпоха 30/300, Ошибка: 4.8444, Test: 5.4001
Эпоха 60/300, Ошибка: 4.7541, Test: 4.9686
Эпоха 90/300, Ошибка: 4.0287, Test: 4.6754
Эпоха 120/300, Ошибка: 3.6920, Test: 4.7168
Эпоха 150/300, Ошибка: 3.2730, Test: 4.4148
Эпоха 180/300, Ошибка: 2.8844, Test: 4.0499
Эпоха 210/300, Ошибка: 2.5511, Test: 4.0553
Эпоха 240/300, Ошибка: 2.3204, Test: 3.9639
Эпоха 270/300, Ошибка: 2.0535, Test: 3.9104
Эпоха 300/300, Ошибка: 1.7912, Test: 3.7730
Обучение завершено. Финальная ошибка: 1.7912
```

1. Кривая обучения SOM...



Выводы:

- Ошибка на тестовой выборке стабильно выше, но следует той же траектории
- Отсутствие переобучения — ошибки на train и test сходятся
- Финальная ошибка: **1.7912** (обучение), **3.7730** (тест)

4.2. Карта SOM с цветовым кодированием

Обучающая выборка

На карте SOM для обучающей выборки наблюдается чёткое разделение на три кластера:


1. **Зеленый кластер (Class 2)**
 - Локализован в левой верхней части карты

- Частично перекрывается с синим кластером
- 2. **Синий кластер (Class 1)**
 - Занимает центральную область
 - Имеет некоторое перекрытие с зеленым кластером
- 3. **Красный кластер (Class 0)**
 - Расположен в нижней правой части карты
 - Наиболее компактный и изолированный кластер
 - Хорошо отделён от других классов

Интерпретация:

- Кластер 2 (зеленый) наиболее отличим по химическому составу
- Кластеры 0 и 1 (красный и синий) имеют больше общих характеристик
- SOM успешно сохраняет топологию данных

Карта SOM для обучающей выборки (красный, синий, зелёный)...




Тестовая выборка

Карта для тестовой выборки подтверждает результаты, полученные на обучающей выборке:

- Три кластера сохраняют свою структуру
- Точки корректно проецируются в соответствующие области
- Хорошая обобщающая способность модели


Карта SOM для тестовой выборки (красный, синий, зелёный)...



4.3. U-Matrix (карта расстояний)

U-Matrix визуализирует средние расстояния между соседними нейронами:

U-Matrix (карта расстояний)...



Анализ:


- **Светлые области** (низкие значения) → кластеры (внутрикластерная близость)
- **темные области** (высокие значения) → границы между кластерами

- Чётко выделяются три кластера
- Граница между красным и синим кластерами наиболее отчётливая
- Граница между синим и зелёным кластерами менее выражена

4.4. Hit Map (карта попаданий)

Hit Map показывает плотность распределения данных по нейронам:

Hit Map (плотность попаданий) ...



Анализ:


- Наиболее плотные области соответствуют центрам кластеров
- Данные хорошо группируются на карте

4.5. Компонентные плоскости

Компонентные плоскости показывают распределение весов каждого признака по карте.

Компонентные плоскости для всех 13 признаков...

Компонентные плоскости SOM для Wine



Наиболее информативные признаки:

1. **Flavanoids (флавоноиды)**
 - Наиболее контрастная плоскость
 - Чётко разделяет красный кластер (высокие значения)
 - Синий и зелёный кластеры имеют низкие значения
 - **Ключевой дискриминантный признак**
2. **Color intensity (интенсивность цвета)**
 - Хорошо разделяет синий кластер (высокие значения)
 - Зеленый и красный кластеры имеют средние значения
3. **Alcohol (алкоголь)**
 - Градиент от красного (высокий) к зелёному (низкий)
 - Хорошо разделяет все три класса
4. **Proline (пролин)**
 - Контрастная плоскость

- Высокие значения в красном кластере
 - Низкие значения в синем
5. **Total phenols (общие фенолы)**
- Паттерн схож с флавоноидами
 - Высокая корреляция с другими фенольными соединениями

Коррелирующие признаки:

- Flavanoids и Total phenols имеют похожие паттерны
 - Alcohol и Proline показывают противоположные градиенты
-

5. Выводы

5.1. Основные результаты

1. **SOM успешно визуализирует 13-мерные данные на 2D карте**
 - Три класса вина чётко разделяются на карте
 - Топологическое свойство сохраняется
2. **Ключевые дискриминантные признаки:**
 - **Flavanoids** — наиболее важный признак
 - **Color intensity** — важен для идентификации Class 0
 - **Alcohol** — разделяет все три класса
 - **Proline** — контрастный для Class 0
3. **Качество кластеризации:**
 - Ошибка квантования: 1.7912 (train), 3.7730 (test)
 - Хорошая обобщающая способность

5.2. Интерпретация визуализаций

Карта SOM:

- Три компактных кластера
- Class 2 наиболее изолирован
- Class 0 и Class 1 имеют зоны перекрытия

U-Matrix:

- Подтверждает наличие трёх кластеров
- Чёткие границы между кластерами

Hit Map:

- Хорошо выраженные центры кластеров
- Плотность попаданий отражает распределение данных

Компонентные плоскости:

- Flavanoids и Color intensity — наиболее важные признаки
- Коррелирующие признаки образуют похожие паттерны

5.3. Практические рекомендации

1. Для визуализации данных:
 - Использовать SOM для первичного анализа структуры
 - Комбинировать с другими методами (PCA, t-SNE)
2. Для выбора параметров:
 - Размер сетки $\approx \sqrt{(5 \cdot \sqrt{N})}$, где N — число образцов
 - Начальные параметры: $\text{lr}=0.5$, $\text{sigma}=3.0$
3. Для интерпретации:
 - Использовать U-Matrix для определения кластеров
 - Анализировать компонентные плоскости для выявления важных признаков

5.4. Заключение

Самоорганизующиеся карты Кохонена являются мощным инструментом для визуализации и анализа многомерных данных. На примере датасета Wine SOM успешно выявила структуру данных, разделила три сорта вина и позволила определить наиболее значимые химические признаки для классификации.

6. Приложение: Код реализации

Основные компоненты реализованы в классе `SOM`:

- Инициализация весов случайными выборками из данных
- Поиск ВМУ с евклидовой и косинусной метрикой
- Вычисление коэффициентов соседства (гауссово окно)
- Алгоритм обучения с экспоненциальным затуханием
- Вычисление ошибки квантования
- Предсказание координат ВМУ

Визуализации реализованы с использованием `Matplotlib`:

- Карта SOM с цветовым кодированием
- U-Matrix
- Hit Map
- Компонентные плоскости
- Кривая обучения